

Presentacion


Daniel Villatoro

January 22, 2020

IOT And Machine Learning

- Conceptos de ML e IOT
- Eficiencia del ML en el IOT
- Tecnicas implementadas de ML en IOT
- IoT Driven Healthcare System for Remote Monitoring of Patients
- Fuentes

El IoT o internet de las cosas ayuda en la interconexión de diferentes estructuras físicas y dispositivos de hardware. Estos pueden ser edificios, vehículos, dispositivos electrónicos y otros dispositivos que están integrados con los actuadores, sensores y software, para que puedan recopilar e intercambiar datos entre ellos.



El aprendizaje automático es básicamente una parte de la informática que hace que cualquier sistema sea lo suficientemente inteligente como para aprender por sí solo sin estar realmente programado para esa tarea y se puede utilizar en diferentes escenarios, como cuando se conoce el resultado requerido (aprendizaje supervisado), cuando los datos no se conocen de antemano (aprendizaje no supervisado) o cuando el aprendizaje depende del resultado de la interacción entre un modelo específico y el entorno (aprendizaje reforzado).



ComputerHope.com

Existen muchos factores para que el Machine Learning sea una realidad esto es gracias a las grandes fuentes de datos, la mayor potencia de cálculo requerida para procesar la información en segundos y diferentes algoritmos que se han vuelto más confiables.

El objetivo principal de ML es automatizar el desarrollo de diferentes modelos analíticos para permitir que los algoritmos aprendan continuamente con la ayuda de los datos disponibles.




En el IoT, a menudo es necesario identificar las correlaciones entre docenas de entradas de sensores y varios factores externos que están produciendo millones de puntos de datos.

Cuando se trata de Machine Learning, comienza directamente con las variables de resultado y luego busca automáticamente diferentes variables predictorias y sus interacciones, por lo tanto el Machine Learning es realmente valioso cuando sabemos lo que queremos pero no sabemos las variables de entrada importantes para tomar esa decisión



Todos los diferentes modelos de datos que se crean utilizando análisis de datos tradicionales son estáticos, pero varios algoritmos de Machine Learning mejoran constantemente con el tiempo a medida que se capturan y asimilan más datos, esto indica que los algoritmos utilizados pueden hacer predicciones, compararlas con sus predicciones pasadas, ver qué sucede realmente y luego ajustarlas para ser más precisas.

Las capacidades predictivas de Machine Learning son extremadamente útiles en entornos industriales, al extraer los datos de múltiples sensores presentes en las máquinas, y aplicando algoritmos de Machine learning se puede aprender lo que es típico de la máquina y también detectar cada vez que algo anormal comienza a ocurrir.



Redes neuronales artificiales: este tipo de técnica de aprendizaje también se denomina redes neuronales, básicamente es un algoritmo de aprendizaje inspirado en la estructura y los aspectos funcionales de las redes neuronales biológicas.

Redes bayesianas: este es un tipo de modelo gráfico probabilístico que representa un conjunto de variables aleatorias con todas sus dependencias condicionales mediante el uso de un gráfico acíclico dirigido.

Aprendizaje del árbol de decisión: el aprendizaje del árbol de decisión es un tipo de técnica de ML que utiliza un árbol de decisión como modelo predictivo. Este modelo asigna las observaciones sobre un elemento a diferentes conclusiones sobre el valor objetivo del elemento.

La motorización remota de parámetros fisiológicos del paciente por medio de el uso de dispositivos portátiles ofrece una mayor flexibilidad para las personas mayores para controlar su salud en casa.

Según la OMS, muchas personas mueren debido a enfermedades crónicas y cardiovasculares. IOT ofrece acceso inmediato a los médicos y hospitales mediante la medición y el procesamiento de los signos vitales de pacientes. Este sistema ayuda al paciente para visitar al médico cada vez que necesite verificar el ECG y la temperatura y el oxígeno del pulso en la sangre.

Los médicos y hospitales podrían hacer uso de datos en tiempo real recopilados en la plataforma que esta en la nube para proporcionar una solución rápida y eficiente.

Los sensores biomédicos, abarcan los parámetros vitales incluyen la temperatura, pulso y ECG estos sensores portátiles son fáciles de llevar en el cuerpo del paciente sin molestar a su rutina diaria, los datos de los sensores se transmiten de forma inalámbrica a un dispositivo IO.

Sensor de temperatura: Este sensor mide el cuerpo temperatura reconoce cambios característicos en el cuerpo que son causados debido a muchas enfermedades.

Sensor de pulso: se utiliza cuando la oxigenación de un paciente es inestable. Una situación incluye emergencia y cuidados intensivos, este sensor determina la necesidad de oxígeno en el cuerpo.

ECGSensor: El ECG sensor mide las funciones musculares y eléctricas del corazón. Mediante el análisis de la forma de onda patrón exacto, podemos identificar los desequilibrios de electrolitos, ritmo, trastornos y arritmias cardíacas.

IO Dispositivo: dispositivo IO incluye tarjetas de desarrollo como los micro controladores de diferentes proveedores. Se utiliza como un sub sistema de procesamiento.

La comunicación del dispositivo se realiza mediante protocolos de RF de corto alcance como ZigBee, de onda Z, Bluetooth, BLE, y Wi-Fi y la puerta de entrada a comunicación via nube utilizando protocolos HTTP.

Nube: Cloud es una red o de Internet, que está presente en la ubicación remota, proporciona servicios a través de la red de redes públicas o privadas en las redes.

Daniel
Villatoro

Conceptos
de ML e
IOT

Eficiencia
del ML en
el IOT

Eficiencia
del ML en
el IOT

Tecnicas
implemen-
tadas de
ML en IOT

IoT Driven
Healthcare
System for
Remote
Monitoring
of Patients

Fuentes

Prashant Salunke and Rasika Nerkar, "IoT Driven Healthcare System for Remote Monitoring of Patients", International Journal for Modern Trends in Science and Technology, Vol. 03, Issue 06, June 2017, pp. 100-103.